HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN I

# BÁO CÁO TUẦN 6

# THỰC TẬP CƠ SỞ

## Đề tài: HỆ THỐNG QUẢN LÝ TÀI CHÍNH CÁ NHÂN THÔNG MINH TÍCH HỢP PHÂN TÍCH HÀNH VI VÀ DỰ BÁO CHI TIÊU

**Giảng viên hướng dẫn** : **TS. Kim Ngọc Bách**
**Họ và tên sinh viên** : **Nguyễn Thị Diệu Ánh**
**Mã sinh viên** : **B23DCCN062**

*Hà Nội - 2026*

# GIAI ĐOẠN: HUẤN LUYỆN, THỬ NGHIỆM VÀ TINH CHỈNH MÔ HÌNH NLP (TUẦN 6)

## I. MỤC TIÊU

Trong tuần 6, sinh viên tập trung vào các mục tiêu chính sau:

- Hoàn thiện pipeline xử lý dữ liệu văn bản từ raw text → clean text.
- Xây dựng mô hình baseline cho hai bài toán:
  - Phân loại danh mục chi tiêu (**Category Classification**).
  - Phân tích cảm xúc (**Emotion Classification**).
- Giải quyết vấn đề mất cân bằng dữ liệu (imbalanced data).
- Đóng gói mô hình phục vụ inference thực tế.

## II. TRIỂN KHAI KỸ THUẬT

### 1. Tiền xử lý dữ liệu (Preprocessing Pipeline)

Dữ liệu đầu vào là câu văn thô (ví dụ: *"mua thuốc cảm hết 200k"*).

Pipeline xử lý gồm:

- Chuẩn hóa văn bản (lowercase, loại ký tự đặc biệt).
- Tách từ tiếng Việt (word segmentation).
- Chuẩn hóa về dạng clean_text.

**Ví dụ:**

| **Raw Text** | **Clean Text** |
|---|---|
| mua thuốc cảm hết 200k | mua thuốc cảm hết |
| ăn bún bò sáng | ăn bún_bò sáng |

👉 Việc sử dụng thống nhất clean_text giúp đảm bảo:

- Train và inference cùng không gian dữ liệu.
- Tránh mismatch feature.

### 2. Biểu diễn dữ liệu (Feature Extraction)

Cả hai bài toán đều sử dụng **TF-IDF Vectorizer**.

#### a. Category Model

TfidfVectorizer(ngram_range=(1, 2), max_features=5000).

**Ý nghĩa:**

- Unigram + Bigram → giữ được ngữ cảnh.
- Giới hạn 5000 features → tránh overfitting.

**Ví dụ:**

- "mua thuốc cảm" →
  → "mua", "thuốc", "cảm", "mua thuốc", "thuốc cảm".

**b. Emotion Model**

TfidfVectorizer()

**Đặc điểm:**

- Không dùng bigram
- Số feature ít hơn (~600 features)

Hai vectorizer này **độc lập hoàn toàn**.

- Tách riêng:
  - vectorizer.pkl (category)
  - emotion_vectorizer.pkl (emotion)

**3. Huấn luyện mô hình (Model Training)**

**a. Category Classification**

- Thuật toán: **LinearSVC**
- Cấu hình:

```
LinearSVC(
  class_weight='balanced',
  max_iter=2000
)
```

**Kỹ thuật áp dụng:**

- **Stratified Split**

train_test_split(..., stratify=y)

→ giữ phân bố nhãn.

- **Class Weight = balanced**
  → tăng trọng số lớp hiếm.

**b. Emotion Classification**

- Thuật toán: **LogisticRegression**
- Cấu hình:

```
LogisticRegression(
  max_iter=200,
  class_weight='balanced'
)
```

Phù hợp với:

- dữ liệu nhỏ.
- baseline model.

**4. Xử lý mất cân bằng dữ liệu**

**Hiện trạng:**

- Một số lớp rất ít mẫu.

**Giải pháp áp dụng:**

- class_weight='balanced'.

**5. Đánh giá mô hình (Evaluation)**

Sử dụng:

```
classification_report(y_test, y_pred)
```

Các metric:

- Precision
- Recall
- F1-score

Thêm cấu hình:

```
zero_division=0
```

→ tránh warning khi class không được dự đoán.

**6. Đóng gói mô hình (Model Persistence)**

Sử dụng joblib để lưu:

category_model.pkl
vectorizer.pkl
emotion_model.pkl
emotion_vectorizer.pkl

**7. Xây dựng lớp suy luận (Inference Layer)**

File: ai_models.py

**Chức năng:**

- Load model + vectorizer.
- Tiền xử lý input.
- Trả kết quả dự đoán.

**Pipeline inference**

Raw Text
↓
clean_text()
↓
vectorizer tương ứng
↓
model.predict()
↓
Output (category + emotion)

**Ví dụ thực tế**

Input:

"mua thuốc cảm hết 200k"

Output:

```
{
 "category": "Sức khỏe",
 "emotion": "Tiêu cực"
}
```

## III. KẾT QUẢ ĐẠT ĐƯỢC

- Xây dựng thành công pipeline NLP hoàn chỉnh:
  - Preprocessing
  - Feature extraction
  - Training
  - Inference
- Mô hình category:
  - Nhận diện tốt các lớp chính.
  - Cải thiện lớp hiếm nhờ class_weight.
- Mô hình emotion:
  - Hoạt động ổn định với Logistic Regression.
  - Phù hợp baseline.
- Đóng gói hoàn chỉnh:
  - Sẵn sàng tích hợp API/backend.

## IV. HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN

### Hạn chế

- Chưa sử dụng deep learning (PhoBERT).
- Dataset nhỏ.
- Chưa dùng oversampling thực sự.
- Emotion model còn đơn giản.
- Chưa tích hợp module Named Entity Recognition (NER) hoặc Regex để bóc tách số tiền.

### Hướng phát triển

- Fine-tune PhoBERT cho emotion
- Áp dụng RandomOverSampler / SMOTE
- Tuning hyperparameters
- Thêm confidence score
- Deploy API (FastAPI)

## V. TỔNG KẾT

Tuần 6 đánh dấu bước chuyển từ xử lý dữ liệu sang xây dựng hệ thống học máy hoàn chỉnh. Việc triển khai thành công hai mô hình baseline cùng với pipeline inference đã tạo nền tảng vững chắc cho việc nâng cấp sang các mô hình học sâu trong các giai đoạn tiếp theo.