HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN I

BÁO CÁO TUẦN 7

THỰC TẬP CƠ SỞ

Đề tài: HỆ THỐNG QUẢN LÝ TÀI CHÍNH CÁ NHÂN THÔNG MINH TÍCH HỢP PHÂN TÍCH HÀNH VI VÀ DỰ BÁO CHI TIÊU

Giảng viên hướng dẫn : **TS. Kim Ngọc Bách**
Họ và tên sinh viên : **Nguyễn Thị Diệu Ánh**
Mã sinh viên : **B23DCCN062**

Hà Nội - 2026

TUẦN 7
Giai đoạn: Hoàn thiện AI Pipeline, Tối ưu mô hình SVM & PhoBERT

I. MỤC TIÊU VÀ VẤN ĐỀ CẦN GIẢI QUYẾT

Trong tuần 7, hệ thống AI tập trung giải quyết các vấn đề cốt lõi nhằm nâng cao độ chính xác và tính ổn định trước khi tích hợp vào Backend:

1. Mất cân bằng dữ liệu (Class Imbalance)

Tập dữ liệu có sự chênh lệch lớn giữa các nhãn (ví dụ: “Mua sắm”, “Ăn uống” chiếm đa số), khiến mô hình có xu hướng thiên lệch (bias) và giảm khả năng dự đoán chính xác các lớp thiểu số như “Học tập”, “Phát sinh”.

2. Hiệu năng mô hình PhoBERT

Mô hình xử lý ngôn ngữ tự nhiên tiếng Việt gặp hạn chế khi:

- Dữ liệu đầu vào chưa được tách từ đúng chuẩn
- Chiều dài chuỗi quá lớn so với dữ liệu thực tế (câu ngắn) → gây lãng phí tài nguyên.

3. Trích xuất thực thể phức tạp: Việc bóc tách số tiền từ câu nói tự nhiên gặp khó khăn do thói quen gõ đa dạng của người Việt (dùng "k", "củ", "tr", "triệu" xen lẫn số thập phân).

4. Thiếu chuẩn hóa hệ thống AI

- Chưa có logging để theo dõi kết quả
- Code chưa module hóa rõ ràng
  → gây khó khăn khi tinh chỉnh và tái sử dụng

II. CÁC GIẢI PHÁP KỸ THUẬT TRIỂN KHAI

1. Nâng cấp Pipeline tiền xử lý

Pipeline được chuẩn hóa theo hướng tối giản nhưng hiệu quả:

- Chuẩn hóa văn bản (lowercase, loại bỏ ký tự đặc biệt)
- Tách từ tiếng Việt bằng thư viện underthesea
- Chuẩn hóa biểu diễn tiền tệ bằng Regex (VD: 150 k → 150k)
- Nối từ ghép quan trọng (VD: trà sữa → trà_sữa)

Kết quả: tăng khả năng học ngữ nghĩa cho cả SVM và PhoBERT.

2. Xây dựng Module Trích xuất Tiền tệ (Amount Extraction)

- Xây dựng luồng xử lý riêng biệt để quét và quy đổi số tiền từ văn bản tự do thành định dạng số nguyên (Integer).
- Ứng dụng biểu thức chính quy (Regular Expression) phức tạp để:
    - Nhận diện mọi biến thể đơn vị tiền tệ phổ biến của người Việt (k, nghìn, ngàn, tr, triệu, củ, đ).
    - Xử lý chính xác các số thập phân có chứa dấu phẩy hoặc dấu chấm (VD: "1.5 triệu" hoặc "1,5 củ").
    - Quy đổi đồng nhất về cùng một đơn vị VNĐ (VD: "1.5 triệu" -> 1500000, "50k" -> 50000).

3. Mở rộng tập dữ liệu (Data Expansion)

Thực hiện bổ sung hơn **200 mẫu dữ liệu gán nhãn thủ công** vào file dataset_v1.csv, tập trung vào các nhóm yếu:

- **Hóa đơn: t**ập trung từ khóa "trọ", "tiền điện", "wifi", "phí dịch vụ".
- **Sức khỏe:** Bổ sung các cụm từ "khám", "thuốc", "nha khoa", "viện".
- **Ăn uống & Mua sắm:** bổ sung để giảm nhiễu.
- Sử dụng nhãn chuẩn do con người đánh giá (Ground Truth - cột Category) làm cơ sở học tập duy nhất.

Giúp cải thiện rõ rệt độ cân bằng dữ liệu và giảm bias

4. Tối ưu mô hình phân loại danh mục (SVM)

Feature Engineering (TF-IDF)

- thiết lập ngram_range = (1, 2) → học cả unigram + bigram
- kích hoạt sublinear_tf = True → giảm ảnh hưởng từ lặp
- max_features = 3000 → tránh overfitting

Model Configuration

- LinearSVC
- Cố định random_state
- class_weight = 'balanced' → xử lý imbalance
- C = 5.0 → tăng khả năng phân tách
- stratify = y → giữ phân bố dữ liệu

Kết quả: cải thiện rõ rệt F1-score và Precision

5. Huấn luyện mô hình cảm xúc (PhoBERT Fine-tuning)

Tiền xử lý đầu vào

- Chuyển đổi dữ liệu huấn luyện từ Raw Text sang clean_text.
- Đảm bảo phù hợp với tokenizer của PhoBERT

Tối ưu tài nguyên

- max_length = 64 phù hợp đặc thù câu giao dịch ngắ.,
- batch_size = 16
- learning_rate = 2e-5
- epochs = 4

Huấn luyện

- Optimizer: AdamW với lr=2e-5 qua 4 epochs.
- Fine-tune trực tiếp mô hình pretrained
- Mô hình và Tokenizer được lưu trữ theo chuẩn save_pretrained của thư viện Transformers.

6. Chuẩn hóa kiến trúc hệ thống

- **Thiết kế Utility Module:** Xây dựng file src/utils.py theo nguyên tắc DRY (Don't Repeat Yourself), chứa các hàm tiện ích dùng chung.

```
ai/
│
├── data/
│  ├── dataset_v1.csv # Dataset gốc do sinh viên tự xây dựng
│  └── dataset_v1_clean.csv # Dataset sau khi tiền xử lý (clean + tokenize)
│
├── │  └── evaluation.txt # Lưu kết quả đánh giá mô hình (Accuracy, F1, ...)
│
├── models/
│  ├── category_model.pkl # Mô hình SVM phân loại danh mục
│  ├── vectorizer.pkl # TF-IDF vectorizer cho category
│  ├── emotion_model.pkl # Mô hình ML baseline cho emotion
│  ├── emotion_vectorizer.pkl # Vectorizer cho emotion model
│  ├── emotion_phobert.pth # Trọng số mô hình PhoBERT fine-tuned
│  └── emotion_phobert/ # Thư mục save_pretrained (config + tokenizer)
│
├── src/
│  ├── ai_models.py # Load model + xử lý Smart Input (category, emotion, amount)
│  ├── amount_extractor.py # Trích xuất số tiền từ câu nhập
│  ├── predict.py # Script test dự đoán
│  ├── preprocess.py # Pipeline tiền xử lý + auto labeling dataset
│  ├── preprocessing.py # Hàm clean_text đơn giản dùng cho model
```

```
│ ├── train_category.py # Train mô hình SVM (category classification)
│ ├── train_emotion.py # Train mô hình cảm xúc (PhoBERT / ML)
│ └── utils.py # Hàm tiện ích (logging, save result,...)
│
└── logs/
  ├── evaluation.txt # Lưu kết quả đánh giá mô hình (Accuracy, F1, ...)
```

- **Hệ thống theo dõi thực nghiệm (Experiment Tracking):** Triển khai hàm save_evaluation_log để tự động ghi nhận thời gian chạy, cấu hình siêu tham số và kết quả Classification Report vào thư mục logs/evaluation.txt, cung cấp minh chứng rõ ràng cho toàn bộ quá trình tối ưu hóa.
- Giúp tái lập thí nghiệm và theo dõi tiến trình

III. KẾT QUẢ ĐẠT ĐƯỢC

1. **Trích xuất thông tin (Extraction):** Hệ thống có khả năng nhận diện và bóc tách chính xác 100% số tiền từ các định dạng gõ tắt tự nhiên của người dùng.
2. **Phân loại Danh mục (Category):** Điểm F1-Score tổng thể đạt mức **0.76 - 0.77**. Các nhãn khó như "Di chuyển", "Giao lưu", "Thu nhập" đạt độ chính xác (Precision) tuyệt đối 1.00.
3. **Phân loại Cảm xúc (Emotion):** PhoBERT được fine-tune thành công, nắm bắt tương đối thái độ người dùng qua các giao dịch tài chính.

Nhãn	**Precision**	**Recall**	**F1-score**
Tiêu cực	1.00	0.55	0.71
Bình thường	0.73	0.90	0.81
Tích cực	0.82	0.74	0.78

4. **Chất lượng Kiến trúc:** Hệ thống AI hoàn thiện dưới dạng Pipeline độc lập (Unified Inference), sẵn sàng nhận đầu vào là chuỗi văn bản và trả về định dạng JSON toàn diện: {text, amount, category, emotion}.